

Datenmanagementbasisplan

Der Datenmanagementbasisplan (DMP) bündelt die Überlegungen zum Datenmanagement des beantragten Projekts. Er ist mit dem Antrag einzureichen und bei wesentlichen Änderungen zu aktualisieren. Mehrfachantworten sind möglich; Erläuterungen können bei Bedarf im Antwortfeld in wenigen Sätzen ergänzt werden.

Version: 1.0, Stand: Juli 2026

1. Allgemeine Angaben	
Projekttitel	Documentation, digitization, and exploration of Ukrainian linguistic diversity (DoDiEx)
Kurzbeschreibung	The project will digitize the linguistic archive of the Institute of the Ukrainian language (Ukrainian Academy of Sciences, Kyiv, Ukraine) as well as published sources on Ukrainian dialects in accordance with current standards in digital humanities and make them available through a sustainable digital infrastructure with multiple layers of annotation, open-access downloads, a user-friendly interface and a mobile app. The collected data will be used for statistical analysis and for the exploration of various factors that have shaped Ukrainian linguistic diversity.
Fachliche Zuordnung	Linguistik
Projektleitung	Ilja Seržant
Datum	08.09.2026
DMP-Verantwortlich <i>Wer hat den aktuellen Plan erstellt und wie ist die Fortführung sichergestellt?</i>	Ilja Seržant
Ist projekteigenes Datenmanagementpersonal vorgesehen?	☒ Ja ☐ Nein (bitte erläutern)
Wie sind die Kosten des Datenmanagements gedeckt?	☒ Die Kosten sind vollständig durch das Budget gedeckt ☐ Die Kosten sind anteilig gedeckt (bitte erläutern) ☐ Die Kosten sind anderweitig gedeckt (bitte erläutern)

2. Erhebung und Dokumentation	
Welche Daten entstehen im Projekt? <i>Skizzieren Sie kurz die Herkunft und den Lebenszyklus der Daten im Projekt. Dies umfasst sowohl Ausgangsdaten, neu erstellte, gesammelte, abgeleitete oder generierte Daten. D.h. auch Zwischenstufen oder ergänzende Daten, die der Nachvollziehbarkeit der Ergebnisse dienen oder diese kontextualisieren. Manchmal auch Primär-, Sekundär- und Tertiärdaten genannt.</i>	The project reuses archival and published source materials on Ukrainian dialects, including handwritten index cards and field notes, dialect maps, dictionaries, printed texts and approximately 1,300 hours of historical audio recordings, primarily use the data from the archive of the Institute of the Ukrainian Language (Kyiv, Ukraine). The data were chiefly collected in the 1950s-1970s in Ukraine and neighboring regions where Ukrainian dialects are spoken. During the project, these source materials will give rise to digital master files (scans and preservation audio), OCR and transcription files, questionnaire- and dictionary-structured datasets, time-aligned and morphosyntactically annotated corpora, as well as sociological, historical and geospatial datasets. Metadata, identifiers, documentation, validation reports and processing scripts will be maintained alongside the research data. The derived datasets will ultimately be interlinked and published in interoperable formats, in particular CLDF.
Nachnutzung von Daten <i>Werden im Vorhaben bestehende Forschungsdaten nachgenutzt?</i>	☐ Nein ☐ Ja, aus eigenen früheren Projekten ☒ Ja, aus externen Quellen und Beständen (z. B. Repositorien, Kooperationspartner) ☐ Noch nicht bekannt
Verwendung von Vokabularen und Standards <i>Wird im Vorhaben auf bestehende Standards, Normdaten und/oder Vokabulare zurückgegriffen?</i>	☐ Nein ☒ Ja ☐ Noch nicht bekannt
Erfassungs- und Verarbeitungsverfahren <i>Welche Software, Technologien oder Verfahren werden zur Erzeugung oder Erfassung der Daten hauptsächlich genutzt? Sofern möglich, sollten Open-Source-Lösungen bevorzugt werden.</i>	The preparation of the data includes OCR conversion of scanned handwritten and published materials into text using software such as Transkribus and additional tools for historical handwritten documents. All proofreading and annotation work will be carried out using the GitLab environment. An institutionally hosted GitLab instance operated by the responsible/host academy will provide version control, issue tracking, access management, backups, and CI/CD functionality while keeping sensitive project data within an institutionally managed, GDPR-compliant environment.
Dokumentationsform <i>Wie und wo werden die Daten, Datenstrukturen und Datenformate dokumentiert (z. B. README, Datenmodell, Data Dictionary, Data Manual, Annotationsmanual)? Welche Metadaten werden geführt und wo werden sie abgelegt? Wird eine Versionskontrolle eingesetzt?</i>	Data structures, metadata fields and processing conventions will be documented in version-controlled README files, data dictionaries/schema documentation and annotation manuals maintained in the institutional GitLab repository. Source catalogues will record bibliographic and archival provenance. Documentation will include file-naming conventions, identifiers, transcription and normalization rules, uncertainty markers, editorial interventions, licensing information and processing history. Changes to data and documentation will be tracked through Git version control and tagged releases.

Qualitätssicherung <i>Welche Qualitätskriterien gelten für die Forschungsdaten, wie wird die Datenqualität sichergestellt, und wer ist verantwortlich? Werden KI-Verfahren eingesetzt? Wenn ja, wie wird ihre Qualität überprüft?</i>	Quality assurance is performed at several stages. Digitized source files undergo initial technical and metadata checks. OCR and automatically generated transcriptions or annotations are manually reviewed by trained project staff. Structured datasets are automatically checked for missing identifiers, duplicates, invalid values and inconsistent coding, followed by scholarly review. CLDF datasets are validated with the CLDF tooling ecosystem before publication. AI-generated normalization, translation or annotation is treated only as preliminary output and is subject to expert verification before inclusion in released research data.
3. Beschreibung der Forschungsdaten	
Datentypen und -modalitäten <i>Welche Forschungsdaten entstehen? Welche Modalitäten liegen den Forschungsdaten zugrunde?</i>	✓ Text ✓ Bild ✓ Audio ☐ Video ☐ 3D ☐ Notation (z. B. Musik, Tanz) ✓ Numerisch (z.B. Geodaten) ☐ Andere:
Rechtliche Einschätzung <i>Wie ist der Rechtsstatus der verwendeten Quellen und Materialien?</i>	Urheberrechtlicher Status ☐ Gemeinfrei (public domain) ☐ Urheberrechtlich geschützt, Nutzungsrechte liegen vor ☐ Urheberrechtlich geschützt, Klärung noch ausstehend ✓ Gemischte Situation (bitte erläutern): The project combines archival materials for which digitization and reuse rights are granted by the IUL with published sources of different copyright status. Copyright and reuse conditions will therefore be documented at source level. Only materials for which the necessary rights are available will be distributed as digital reproductions; derived research data will be licensed separately where legally possible. Persönlichkeitsrechtlicher Status ☐ Nicht einschlägig (keine personenbezogenen Daten enthalten) ☐ Persönlichkeitsrechtlich geschützt, Einwilligungen liegen vor ☐ Persönlichkeitsrechtlich geschützt, Klärung noch ausstehend ✓ Gemischte Situation (bitte erläutern): The archival materials may contain personal or potentially identifying information, in particular speakers' names, voices and demographic information associated with historical audio recordings. The legal and ethical status of such material will be assessed before publication. Where necessary, identifying metadata will be removed, pseudonymized or access-restricted. Only data for which publication is legally and ethically permissible will be made openly accessible.
Geschätztes Datenvolumen <i>Wie groß ist das voraussichtliche Gesamtvolumen der entstehenden Forschungsdaten?</i>	☐ < 100 GB ☐ 100 GB – 1 TB ☐ 1 – 10 TB ✓ 10 – 100 TB ☐ > 100 TB ☐ Noch nicht abschätzbar

Dateiformate <i>Welche Dateiformate werden verwendet? Offene, langzeitstabile Formate sind zu bevorzugen.</i>	✓ TXT ✓ XML ✓ PDF/A ✓ TIFF / JPEG ✓ CSV / TSV ✓ RDF / JSON-LD ✓ MP3 / WAV ☐ MP4 / MKV ☐ Proprietäre Formate (bitte benennen): ☐ Andere:
Fachspezifische Standards <i>Welche fachspezifischen Datenstandards und Vokabulare werden eingesetzt?</i>	✓ XML/TEI (Text Encoding Initiative) ☐ XML/CEI (Charter Encoding Initiative) ☐ XML/MEI (Music Encoding Initiative) ✓ IIIF (International Image Interoperability Framework) ☐ LIDO (Lightweight Information Describing Objects) ☐ CIDOC CRM (Conceptual Reference Model) ☐ GND (Gemeinsame Normdatei) ☐ AAT (Art & Architecture Thesaurus) ☐ MARC / MARCXML (Machine-Readable Cataloging) ☐ Noch nicht festgelegt ✓ Andere: CLDF (Cross-Linguistic Data Formats); Universal Dependencies / CoNLL-U; ELAN/EAF; IPA; CLTS; Concepticon; Glottolog/Glottocodes; controlled project vocabularies.
4. Speicherung, Sicherung und Langzeitarchivierung	
Speicherung während der Projektlaufzeit <i>Wo werden die Forschungsdaten während der Projektlaufzeit gespeichert?</i>	✓ Institutioneller Server ☐ (Hochschul-)Cloud-Dienst ✓ Lokaler Rechner (nur ergänzend) ☐ Andere:
Backup-Strategie <i>Wie und wie oft werden die Daten gegen versehentlichen Verlust geschützt?</i>	Primary project data will be stored on institutionally managed servers at BBAW, with an additional geographically separate copy maintained in cooperation with the IUL in Ukraine. Version-controlled working data and code will be maintained in the institutionally hosted GitLab environment. Automated server-side backups will be performed regularly and retained according to the responsible institution's backup policy. Backup integrity and restoration procedures will be checked periodically.
Zu archivierende Daten <i>Welche Daten sind für die Archivierung vorgesehen?</i>	✓ Alle erhobenen / erzeugten Daten ☐ Ausgewählte, archivwürdige Daten (Auswahlkriterien sind dokumentiert) ☐ Nur Rohdaten ☐ Nur Enddaten / Publikationsdaten ☐ Noch nicht festgelegt

Anbindung an Forschungsdateninfrastrukturen <i>Wie und in welcher Form findet eine Anbindung an fachspezifische Forschungsdateninfrastrukturen statt (z. B. NFDI-Konsortien, CLARIAH)?</i>	The project will be embedded in the research infrastructure of the BBAW Zentrum Sprache and will cooperate with relevant BBAW digital-humanities infrastructure and expertise, including TELOTA/ELAR-related expertise. Linguistic datasets will additionally follow CLDF and other community standards to facilitate interoperability with disciplinary infrastructures.
Langzeitarchivierung <i>Wie und durch wen werden die Daten nach Projektabschluss langfristig archiviert? In welcher Form geschieht dies, und wie können die Daten gefunden und wiederhergestellt werden? Möglichst Letter of Intent der zuständigen Institution beilegen.</i>	Stable releases of the research datasets, accompanying documentation and processing code will be deposited in a trusted repository such as Zenodo and assigned persistent DOIs. Preservation master files that are not suitable for repository deposition because of their size will be retained within the institutional storage infrastructure of BBAW and, where applicable, the IUL. The project website will provide access to current versions, while repository deposits will preserve citable release versions independently of the website. Responsibilities for long-term preservation, integrity checking, migration and recovery will be coordinated with the responsible BBAW infrastructure. A corresponding institutional commitment / Letter of Intent will be obtained where required.
Aufbewahrungsdauer <i>Wie lange sollen die Forschungsdaten nach Projektabschluss aufbewahrt werden?</i>	☐ Mindestens 10 Jahre ☒ Dauerhaft ☐ Noch nicht festgelegt
Persistente Identifikatoren <i>Welche persistenten Identifikatoren werden vergeben, um dauerhafte Zitierbarkeit und Auffindbarkeit zu sichern?</i>	☒ DOI ☐ URN ☐ GND ☐ Handle ☐ Andere:
Zeitpunkt der Veröffentlichung <i>Wann werden die Forschungsdaten veröffentlicht?</i>	☐ Unmittelbar nach der Erhebung ☒ Kontinuierlich während der Projektlaufzeit ☐ Mit Abschluss des Projekts ☐ Mit Erscheinen der zugehörigen Publikation(en) ☐ Nach Ablauf einer Sperrfrist (bitte erläutern):
5. Nachnutzung, Auffindbarkeit und verantwortungsvoller Umgang	
Open Data <i>In welchem Umfang werden die Forschungsdaten offen zugänglich gemacht?</i>	☐ Vollständig Open Data ☒ Teilweise offen (bitte begründen): ☐ Nein, eingeschränkter Zugang (bitte begründen): All research data will be made openly available whenever copyright, data-protection and personality-right considerations permit. Sensitive or identifying information contained in historical recordings and metadata will be removed, pseudonymized or access-restricted. Licensing will be documented at dataset and, where necessary, source level.

FAIR-Prinzipien <i>Wie werden die Prinzipien der Auffindbarkeit (Findable), Zugänglichkeit (Accessible), Interoperabilität (Interoperable) und Nachnutzbarkeit (Reusable) der Forschungsdaten im Projekt umgesetzt?</i>	Findable: stable dataset releases will receive DOIs and rich bibliographic and provenance metadata. Accessible: openly releasable data will be available through the DoDiEx website, machine-readable downloads/APIs and a public repository; justified access restrictions will be documented. Interoperable: data will use community standards including CLDF, TEI, Universal Dependencies/CoNLL-U, ELAN and GeoJSON, stable project identifiers and established linguistic reference catalogues. Reusable: datasets will include explicit licenses, source information, provenance, annotation and normalization documentation, version information, validation reports and the scripts required to reproduce major processing steps.
Sind die CARE-Prinzipien für die im Projekt entstehenden oder genutzten Daten relevant? <i>Ethische Leitprinzipien für Daten zu indigenen und marginalisierten Gemeinschaften: Collective Benefit, Authority to Control, Responsibility, Ethics.</i>	✓ ☒ Nein ☐ Ja Falls ja, bitte kurze Darstellung des geplanten Umgangs mit den CARE-Prinzipien im Projekt: